

DQN을 이용한 수요응답형(DRT) 대중교통차량 최적 경로 탐색

Exploring the optimization of DRT Public transport vehicle routes using a Deep-Q network

김승학¹ · 장진호² · 성기영³ · 김현⁴

¹한국교통대학교 교통ICT 융합연구센터 연구원, ²서울대학교 식물생산과학부 산업인력개발학 전공

³한국교통대학교 교통에너지융합학과 박사과정, ⁴한국교통대학교 교통에너지융합학과 부교수

I. 서론

1. 연구의 배경 및 목적

최근 카카오(Kakao)와 우버(Uber)와 같은 공유 택시 플랫폼이 등장함에 따라 실시간 호출 서비스가 가능하게 되었다. 이는 실시간자율주행 대중교통 모빌리티 서비스가 활발히 진행되는 계기가 되었고 Q-learning방법론을 이용한 수요대응 자율주행 대중교통 연구가 진행되었다.(Kim et al, 2022).

대중교통은 일반적으로 고정노선으로 운행이 되는 반면, 실시간 호출 서비스(DRT, Demand Responsive Transit)는 기존의 버스처럼 운행노선을 정하지 않고 스마트폰 앱으로 호출을 받아 운행하는 방식을 말한다. 실시간 자율주행 대중교통 모빌리티 서비스가 실현되기 위해서는 실시간 동적 노선을 고려한 최적 경로를 생성하는 배차(dispatching) 알고리즘 연구가 필요하다. 하지만 국내의 경우 배차알고리즘 연구보다 DRT 효과분석에 한정된 연구가 진행된 반면, 국외의 경우 차량 경로최적화(vehicle routing optimization)와 호출운용(Order dispatching), 차량 재배치(Vehicle repositioning)등 강화학습(Reinforcement Learning) 방법론을 이용하여 알고리즘 연구가 활발히 진행되고 있다.(Bo Peng et al. 2020).

2. 강화학습 및 DQN(Deep-Q-Network) 알고리즘

강화학습은 기계 학습의 한 영역으로, 어떤 환경(Environment)안에서 정의된 에이전트(Agent)가 현재의 상태(State)를 인식하여, 자신이 선택할 수 있는 가능한 모든 행동(Action)들 중 보상(Reward)을 최대로 가지는 행동을 선택하는 방법이다. 대표적인 모델로 MDP(Markov Decision process)가 있으며 $\langle S, A, P, R, \gamma \rangle$ 를 tuple로 정의한다. S는 가능한 상태, A는 행동의 집합, P는 전이 확률 Matrix, R은 보상, γ 은 decay-factor이다. MDP는 현재 상태에서 에이전트가 액션을 선택은 다음상태와 보상을 결정한다. 이러한 모델을 통하여 상태에 따라 어떤 액션을 선택하였을 때 보상을 최대로 받을 수 있는 함수를 정책(Policy)라고 하며, 최적의 정책을 찾는 학습과정을 Q-learning한다.(Sutton et al. 2020).




그림 1. 강화학습 Markov Decision Process

선행연구에서 진행된 Q-learning 방법론은 상태-행동 $Q(s,a)$ 에 해당하는 Q-value인 q-table형식으로 저장하여 계산에 사용되는데 이러한 방식은 Space(공간)영역이 커지게 되면 memory 문제와 탐색 시간(exploration time) 즉, 계산

시간이 많이 필요하게 되는 한계점이 존재한다.

따라서 본 연구에서는 G-learning의 문제점을 개선하기 위해 Q-function을 비선형 함수로 근사시켜 기존의 개발된 환경, 상태, 행동 등을 참고하는 강화 알고리즘 방법론인 DQN(Deep Q-Network) 적용하여 배차알고리즘 분석을 수행하고자 한다.

II. 본론

1. 강화학습 실험 환경 구축

본 연구의 수요응답형 최적 경로 탐색 알고리즘 환경은 오픈 소스 기반 강화학습에 필요한 환경을 제공하여 강화 학습알고리즘을 개발하고, 검증에 활용되는 Open AI Gym을 이용해 한국교통대학교 캠퍼스와 대학로 교차로 교차로 환경을 구축하였다. 승객이 승·하차 할 수는 정류장은 총 13개로 기존에 주행 중인 버스노선에 수요가 많을 것으로 예상되는 기숙사 주변을 추가적으로 정의하였다.

본 논문 강화학습 실험환경은 크게 3가지 조건을 가정하여 진행하였다.

첫째, 승객이 탑승하는 정류장은 현재 내 위치가 아닌 지오펜싱을 통해 현 위치에서 가장 가까운 위치에 있는 고정형 정류장으로 승객들이 직접 이동한다.

둘째, 승객의 In-vehicle, accept-time은 고려하지 않았다.

셋째, 승객이 승·하차하는 시간은 차량이 정류장에서 약 2초간 정차하도록 설정하였다. 또한 분석을 위한 호출수요는 실제 승객이 요청한 데이터 셋이 아직 존재하지 않기 때문에 현재 한국교통대학교 교내에서 서비스 중인 일렉클 전기자전거의 O-D(Origin-Destination) Dataset을 기반으로 실제 수요가 많은 지역에 상대적으로 확률분포를 크게 주어, 사용자들의 Call을 발생 시켰을 때 배차요청에 대해 1대의 차량이 수행하는 것을 분석 활용하였다.




그림 2. 한국교통대학교 일렉클 전기자전거 O-D Data

2. 강화학습 상태, 액션정의

강화학습의 알고리즘은 주어진 환경 속에서 에이전트가 최적의 정책을 통해 가장 최대의 보상을 가져다주는 행동이 무엇인지 학습하는 것이다. 본 논문은 승객으로부터 콜을 요청 받아 배차

에 성공했을 경우 대중교통차량이 최대로 수용 할 수 있는 승객들의 대기시간을 줄이며, 최단 시간·거리로 경로를 생성하여 수행하는 것에 목적을 두고 있다.

$$\text{Minimize } \sum_{i=1}^{imax} (2t_{now} - t_i^{call} - t_i^{travel}) \quad (1)$$

t_{now} : 현재시간
 t_i^{call} : i번째 승객의 호출시간
 t_i^{travel} : i번째 승객의 탑승시간

대중교통차량의 액션은 크게 4가지로 상하좌우 방향으로 움직인다. 시간에 따른 상태 변화는 현재 차량의 위치 및 방향, 현재 차량에 탑승한 인원수, 현재 탑승객의 목적지, 발생한 수요 승·차 정류장으로 정의하였다.

대부분 강화학습 정책은 탐험(exploration)이 충분하지 않기 때문에 여러 곳을 방문하면서 Q-value값을 update시키는 ϵ greedy 방식을 채택한다. 하지만 현재 교통대학교 환경은 노선이 한 가지로 제한적이기 때문에 greedy-Policy를 적용하였으며 U턴이 아닌 구간은 직진, U턴인 구간은 좌·우·직진 중 현재 상태에서 최상의 액션을 취하도록 하였으며, 버스정류장에서 반드시 정차 하도록 하였다.

3. 시뮬레이션 실험

Open AI Gym를 이용하여 10x 150의 그리드 맵 환경에서 시뮬레이션을 진행하였다. 상단에는 현재 차량의 위치 정보와 맵 전체의 정보를 표출하고 있으며, 하단 좌측은 현재 승객들이 호출하여 대기 정보를, 우측은 현재 차량에 탑승한 승객들의 정보를 담고 있다.




그림 3. Open AI gym 기반 환경 UI

차량의 동작에 따른 보상은 선행 연구에서 최단거리 경로로 학습될 수 있도록 식(2)과 같이 보상값을 정의하였다. 승·하차가 아닌 경우 매 행동마다 -10의 보상값을 주었다. 또한 승차시키는 데에만 중점을 두지 않고, 승차 이후 목적지 까지 서비스 제공을 위해 하차 시 보상값을 크게 주었다. 이점을 참고 하여 추가적으로 본 논문의 목적 함수인 현재 대기 중인 승객들이 교통 상황을 고려하여 약 15분을 초과 했을 경우 -200 보상 값을 주어 대기 중인 승객들을 최소 하여 학습 할 수 있도록 하였다.

$$R(s_t, a_t) = \begin{cases} -10, & \text{if } A_t \neq A_t^{stop}, t = 1, 2, \dots, T \\ -200, & \text{if } t_{wait} \geq 15 \\ 500, & \text{otherwise} \end{cases} \quad (2)$$

$R(s_t, a_t)$: 현재 상태 s_t 에서 현재 행동 a_t 을 선택 했을 때 보상
 A_t^{stop} : t시간에 대해서 정지 행동

t_{wait} : 승객이 호출 후 대기시간

에피소드 게임 종료 조건은 다음과 같다. 첫째, 승객이 호출, 차량에 탑승 시간, 각 정류장 마다 승·하차를 위한 정차 등을 고려했을 때 최대 1시간이 경과했을 경우 종료한다.

둘째, 버스가 수용 할 수 있는 최대 인원이 승차 했을 경우 더 이상 수요 콜을 받지 않고 승객이 모두 하차 후 게임을 종료한다.

셋째, 승객이 호출을 요청하였지만 대기시간이 약 25분 이상 경과 됐을 경우에 에피소드는 종료하게 된다.

표 1. 시뮬레이션 환경변수 설정

learning Rate	5e-4
decay Factor	0.995
Start Epsilon	1.0
End Epsilon	0.01
Episode	10,000

III. 결론 및 향후 연구

본 논문은 DQN을 이용하여 실시간 호출시 실시간으로 동적 노선을 고려한 대중교통차량 최적 경로를 생성하는 알고리즘을 구현하였다. 구현된 환경은 네트워크가 다소 단조로워 에이전트가 선택할 수 있는 행동들이 제한적이다. 실제 도로 네트워크는 이보다 더 복잡하기 때문에 인천 영종도에서 DRT 서비스를 운영 했던 I-MOD의 데이터를 기반으로 실제 도심 내에 환경에 맞는 최적의 경로 탐색과 1대의 차량이 아닌 수요와 공급을 예측하여 최적의 차량 대수와 그에 따른 각 차량들 간에 승객들을 적절히 분배시키는 알고리즘을 추후 연구 할 예정이다.

참고문헌

- 김현, 유선형, 이진우, 백범열, 신정희. (2022). 유턴을 고려한 교통축 적용 수요대응 자율주행 대중교통(DRDTO)의 실시간 동적 경로 생성 알고리즘. 대한교통학회지, 40(2), 260-276.
- Junsu PARK, Jinhee KIM, Jaehyung LEE. (2022). Optimal Fleet Size for Demand Responsive Transport Service Using Queueing Theory : Focusing on the Case of Yeongjong Island, Incheon. Journal of Korean Society of Transportation, 40(6), 816-831. doi:10.7470/jkst.2022.40.6.816
- Peng, Bo, Jiahai Wang, and Zizhen Zhang. "A deep reinforcement learning algorithm using dynamic attention model for vehicle routing problems." International Symposium on Intelligence Computation and Applications. Springer, Singapore, 2020.
- Mnih, Volodymyr, et al. "Playing atari with deep reinforcement learning." arXiv preprint arXiv:1312.5602 (2013).
- Otterlo, Martijn van; Wiering, Marco (2012). Reinforcement Learning and Markov Decision Processes. Adaptation, Learning, and Optimization p.3-42
- Reinforcement Learning An Introduction second edition Richard S. Sutton and Andrew G. Barto p.47-67